

Hissə C – Analitik Hesabat

C1. Çətinliklər və Həllər

Dataset problemi

Tapşırıqda Mozilla Common Voice (az) dataseti tövsiyə edilmişdi. Hugging Face hesabı açıq idi, dataset səhifəsindən giriş icazəsi də alınmışdı. Buna baxmayaraq, fərqli versiyalarla ardıcıl xətlər alındı.

- *common_voice_17_0*: Bu versiya artıq Parquet formatına keçib, köhnə loading script silinib. Ona görə `trust_remote_code` parametri işləmir, data faylları da tapılmır (`EmptyDatasetError`).
- *common_voice_16_1*, *common_voice_13_0*: Alternativ versiyalar da yoxlandı. Nəticə eyni idi – autentifikasiya olsa belə dataset açılmırdı.
- *common_voice_11_0*: Bu versiya isə HF Hub-da tamamilə əlçatansız olaraq qeyd olunub (`DatasetNotFoundError`).

Problemin kökü **Mozilla CV-nin gated dataset strukturundan** irəli gəlir: token və icazə olsa da, Kaggle mühitindən HF Hub-a autentifikasiya axını tam işləmirdi. Vaxtı itirməmək üçün **google/fleurs [az_az]** datasetinə keçdim. FLEURS açıq şəkildə əlçatandır, 16 kHz audio, reference transkripsiyayı özündə saxlayır, streaming rejimini tam dəstəkləyir – ASR qiymətləndirməsi üçün Mozilla CV ilə eyni texniki tələbləri qarşılayır.

VRAM məhdudiyyəti (OOM xətası)

Fine-tuning mərhələsində `whisper-medium` və `whisper-large-v3` modelləri Kaggle T4 GPU-da (15.6 GB VRAM) yüklənərkən **Out-of-Memory** xətası aldım. `fp16` rejimində gradient hesablaması, optimizər vəziyyəti və aktivasiyaların toplam yaddaş tələbatı mövcud VRAM-ı aşırırdı.

Problemi həll etmək üçün `whisper-small` modeli seçildi. Bu model ~242M parametərə malikdir, yalnız ~1.5 GB VRAM tələb edir və eyni Whisper arxitekturası üzərində qurulmuşdur. Bu seçim sayəsində `early stopping`, `learning rate scheduling` və ən yaxşı checkpoint saxlama kimi əsas elementləri ehtiva edən tam fine-tuning pipeline-ı quruldu.

Azərbaycan dilinin ASR-ı çətinləşdirən xüsusiyyətləri

- **Aqqlütinativ morfologiya**: Bir kök sözə ardıcıl şəkilçilər artırılaraq uzun söz formaları yaranır. Bu, effektiv lüğəti böyüdür və modelin tanımalı olduğu variant sayını artırır.
- **Xüsusi simvollar**: ə, ö, ü, ğ, ı, ş, ç kimi hərflər Whisper tokenizer-inin standart Latin əlifbasına yönəlik olduğu üçün bəzən parçalanır, bu da çevirməni çətinləşdirir.
- **Az training datası**: Azərbaycan dili low-resource kateqoriyasına aiddir. Whisper əsasən resurs baxımından zəngin dillər üzərində öyrədilmişdir. Azərbaycancaya ayrılan training datası nisbətən kiçikdir, bu isə modelin dil modelləşdirməsi üçün yetərli kontekst qura bilməməsinə gətirib çıxarır.
- **SOV söz sırası**: Azərbaycan dili Subject-Object-Verb (SOV) söz sırasına malikdir. Bu, ingilismərkəzli şəkildə öyrədilmiş Whisper modelinin sintaktik gözləntilərindən köklü şəkildə fərqlənir. Model feli cümlənin sonunda

gözlənilməyən yerində gördükdə söz sırasını yenidən düzəltməyə çalışır, bu isə səhv transkripsiyalara səbəb ola bilər.

C2. Nəticələrin Təhlili

Hissə A üçün WER/CER nəticəsi qəbul edilə biləndir. Whisper-large-v3-ün heç bir Azərbaycan-spesifik fine-tuning olmadan corpus WER: 19.86%, CER: 4.76% göstərməsi güclü bir nəticədir. CER-in bu qədər aşağı olması xüsusilə diqqətçəkicidir. Model hərflər səviyyəsində Azərbaycan fonetikasını tutmuşdur, yanlışlıqların böyük hissəsi söz səviyyəsindədir, hərf səviyyəsindən yox. Bu, modelin Azərbaycan dilinin fonetikasını müəyyən qədər öyrəndiyini göstərir.

Hissə B üçün nəticə gözləniləndir, lakin baseline-dən yüksəkdir. whisper-small modelinin yalnız 200 nümunə ilə fine-tuning-dən sonra 44.01% WER göstərməsi pis görünə də, bunun arxasındakı məntiq aydındır: whisper-large-v3 ilə whisper-small arasında 6x ölçü fərqi (1543M vs 242M parametrlər) mövcuddur, training datası isə son dərəcə məhduddur. Validation WER step 10-dakı 58.9%-dən step 110-da 50.0%-ə düşüb – model öyrənir, sadəcə baseline-a çatmaq üçün daha çox data lazımdır. Whisper-small zero-shot rejimdə test edilsəydi WER 44%-dən də yüksək olardı; fine-tuning əslində bu modeli öz potensialının üzərinə çıxarmışdır.

Overfitting baş vermədi. Həm train, həm də validation loss axıra qədər ardıcıl azaldı, heç bir nöqtədə artmadı. İkisi arasındakı fərq (0.22 vs 0.88) isə sadəcə normal generalization gap-dır: kiçik model training datanı val setindən daha yaxşı əzbərləyir, bu gözləniləndir. Early stopping isə overfitting-ə görə yox, validation WER-in plateau-ya çatmasına görə (step 110-da 50.0%) işə düşdü.

Model hansı növ xətlər edir?

- **Fonetik:** 'quyruqlu' → 'qoyruqlu', 'toqquşduğu' → 'topuşduğu'. Model akustik cəhətdən oxşar fonemlər arasında çaşır.
- **Leksik:** 'faciəvi qəza' → 'fəziyyəti qəza'. Nadir söz və terminlər üçün model ən yaxın tanıdığı variantı seçir.
- **Uzun cümlə:** Test nümunələrindən ən pis nəticə göstərən hallar uzun və mürəkkəb cümlələrdə oldu. Məsələn, ABŞ Geoloji Xidmətlər Bürosu haqqında cümlə (43.5% WER) çox uzun idi və çoxlu xüsusi isim var idi. Model bu cür cümlələrdə yerini itirərək həm xüsusi isimləri, həm cümlə strukturunu yanlış qaydada tanıdı.
- **Böyük hərf/durğu:** Model tez-tez cümlə başını böyük hərflə yazır və əlavə vergül qoyur. Normalizasiyadan sonra bu fərq azalır.

Hansı şəraitdə model daha yaxşı/pis işləyir?

- **Daha yaxşı:** qısa, sadə cümlələr; stüdio keyfiyyətli səs; elmi/texniki leksika.
- **Daha pis:** uzun cümlələr (20+ san.); xüsusi isimlər, yer adları və terminologiya; kod-switching (Azərbaycan-İngilis qarışığı)

C3. Yaxşılaşdırma Yolları

Production-a aparmaq üçün nə lazımdır?

- **Data:** Mövcud 200 nümunə production üçün yetərsizdir. Minimum 1000–5000 nümunə, mənbə kimi AzTV arxivləri, podcastlar və Mozilla Common Voice nəzərdən keçirilə bilər. Data çeşidliliyi — yaş, cins, dialekt — kritik əhəmiyyət daşıyır.
- **Model:** whisper-large-v3 üzərindən Azərbaycan-spesifik fine-tuning aparılmalıdır. LoRA kimi parametr-effektiv metodlar həm VRAM tələbatını azaldır, həm catastrophic forgetting-in qarşısını alır.
- **İnferens:** ONNX export ya da CTranslate2 ilə quantization real-time istifadə üçün vacibdir.
- **Post-processing:** Dürğu işarəsi bərpası, domain lüğətləri və confidence score-a əsaslanan filtrasiya tətbiq edilməlidir.
- **Monitoring:** Real-time WER izləmə, istifadəçi feedback mexanizmi və active learning dövryyəsi qurulmalıdır.

Daha çox resurs olsaydı, növbəti 3 addım:

1. **Böyük miqyaslı data toplama.** AzTV, İctimai TV arxivləri, podcastlar və parlament yayımları əsasında 500–1000 saatlıq korpus qurardım. Avtomatik segmentasiya üçün MFA (Montreal Forced Aligner), keyfiyyət filtresi üçün SNR həddi tətbiq edilərdi.
2. **whisper-large-v3 tam fine-tuning.** Toplanmış dataset ilə böyük modeli Azərbaycan dili üçün fine-tune edərdim. Azərbaycan əlifbasına uyğun tokenizer genişləndirilməsi, curriculum learning (səadən mürəkkəbə) və n-gram dil modeli ilə beam search integrasiyası aparılardı.
3. **Production API və davamlı öyrənmə.** FastAPI əsaslı ASR mikroservisi qurulardı. Azərbaycan dili üçün xüsusi punctuation restoration modeli əlavə edilərdi. İstifadəçi düzəlişləri yeni training datası kimi toplanaraq active learning dövryyəsi yaradılardı.

Ən böyük problem:

Azərbaycan dili üçün ASR-ın ən böyük problemi keyfiyyətli, geniş miqyaslı açıq nitq datasının olmamasıdır — çünki ən güclü model belə yetərli training datası olmadan öz potensialını reallaşdırma bilmir.